

Modelo de Hopfield

$$h_i(t) = \sum_{j=1}^N w_{ij} s_j(t)$$

$$P(s_i(t+1) = 1) = \frac{e^{\beta h_i(t)}}{e^{\beta h_i(t)} + e^{-\beta h_i(t)}}$$


$$= 1 - P(s_i(t+1) = -1)$$

$$w_{ij} = \frac{1}{N} \sum_{u=1}^U x_i^u x_j^u$$

$$m^u = \frac{1}{N} \sum_{j=1}^N x_j^u < s_j^u >$$

$$s_j^u = \text{sgn}(x_j^1 + x_j^2 + x_j^3)$$

$$m^1, m^2, m^3 \sim O(1), \quad m^u \sim O\left(\frac{1}{\sqrt{N}}\right) \quad u > 3$$



$$m^{(3)} = m_1 = m_2 = m_3$$

región donde
desestabiliza
los estados
mezcla (=0)
y no al origina ($m_1 \neq 0$)

desventajas Hopfield : - todos los neuronos conectados con todos (en la realidad está conectado con \sim un 10%)

generalizaciones del modelo de Hopfield

(1) Dilución en las condiciones

Consideramos un modelo en el cual

$$w_{ij} = \frac{c_{ij}}{K} \sum_{\mu=1}^p x_i^{\mu} x_j^{\mu}$$

$$\text{con } c_{ij} = \begin{cases} 1 & \text{prob } K/N \\ 0 & \text{prob } 1-K/N \end{cases}$$

si miramos la neurona i

\Rightarrow está está conectada con N neuronas con una prob K/N

\Rightarrow el # medio de conexiones por neurona es K

se puede elegir


$$c_{ij} / c_{ji} = c_{ji}$$

\nearrow se puede hacer la misma cuenta del caso campo medio

c_{ij} y c_{ji} son independientes

\downarrow biológicamente más interesante \nearrow no hay simetría en las conexiones (*)

(*) se obtiene el sig. diagrama de fases



\rightarrow diagrama similar

\Rightarrow el modelo es robusto

respecto a cortar

conexiones, siempre

que se respete la

simetría de conexiones


(*) tomamos c_{ij}, c_{ji} ind \rightarrow consideramos el caso $T=0$

$$1 \ll K \ll N$$

$$s_i(t+1) = \text{sgm} \left(\sum_{j=1}^N w_{ij} s_j(t) \right)$$

Consideremos la neurona i a tiempo t

El estado está determinado por un conjunto de k neuronas que están conectadas con ella



k^1
 $t=0$

conexiones

neurona 44
neurona 11
neurona 1
neurona 2

$P(44, 1) = \frac{k}{N}$ (neurona 1 tiene k conexiones)

$P(44, 2) = \frac{k^2}{N}$ (neurona 2 tiene k^2 conexiones)

$$P(44, (1, 2)) = \frac{k^3}{N} \ll 1$$

$$k \propto \log(N)$$

a tiempo 0 : $s_i(0) / \sum_{j=1}^N x_j^1 s_j(0) = m_i(0)$

condición inicial \rightarrow overlap

queremos calcular $m_1^{(1)} = \frac{1}{N} \sum_{j=1}^N x_j^1 s_j(1)$

hay un sobre overlap significativo en la cond. inicial

$$= \frac{1}{N} \sum_{j=1}^N x_j^1 \log \left(\sum_{k=1}^N w_{kj} s_k(0) \right)$$

$$= \frac{1}{N} \sum_{j=1}^N x_j^1 \log \left(\sum_{k=1}^N w_{kj} s_k(0) \right)$$

$= \langle \log m(m_1(0) + R(0)) \rangle$

prom. respecto al ruido


mismos cuantos que antes

$$m_1(t+1) = \langle \log(m_1(t) + R(t)) \rangle$$

se puede pensar que el ruido que me da una neurona repetido, dice que $R(t)$ y $R(t')$ son v.a independientes

$$m_1(t+1) = \int_{-\infty}^{\infty} \frac{dR}{\left(\frac{2\pi p}{K}\right)^{1/2}} e^{-R^2/(p)} \operatorname{sgn}(m_1(t), R)$$

$$= \operatorname{erf}\left(\frac{m_1(t)}{\sqrt{2\alpha'}}\right) \quad \alpha' = \frac{p}{K}$$



tenemos conexiones muy diluidas e independientes,
 si uno quiere el overlap en función del # de
 conexiones \rightarrow el comportamiento no es muy diferente

(2) Bajo nivel de actividad

$$W_{ij} = \frac{1}{N} \sum_{u=1}^p x_i^u x_j^u$$

temíamos $x_i^u = \pm 1$ con igual probabilidad



ahora : $x_i^u = \pm 1$ $\left\{ \begin{array}{l} P(x_i^u = 1) = \frac{1+a}{2} \\ P(x_i^u = -1) = \frac{1-a}{2} \end{array} \right. \Rightarrow \langle x_i^u \rangle = a$


$$s_j(0) = x_j^1$$

$$s_j(1) = \operatorname{sgn}\left(\sum_{i=1}^N W_{ij} s_i(0)\right) = \operatorname{sgn}\left(\frac{1}{N} \sum_{u=1}^p x_i^u x_j^u x_j^1\right)$$

$$= \text{sgn} \left(x_i^1 + \underbrace{\sum_{u>1} \sum_j \frac{1}{N} x_j^u x_j^u x_j^1}_{\mathcal{N}((p-1)\alpha^3, \sigma^2=(p-1)N)} \right)$$

$n_i \dots \dots$
 $\text{sgn} = 1$ ind de x_i^1

media grande $\neq 0!!$
 se puede calcular



comenciamos la regla: $w_{ij} = \frac{1}{N} \sum_{u=1}^p (x_i^u - a)(x_j^u - a)$


$$\begin{aligned}
 s_i(1) &= \text{sgn} \left(\frac{1}{N} \sum_{u,j} (x_i^u - a)(x_j^u - a) x_j^1 \right) \\
 &= \text{sgn} \left(\frac{1}{N} \sum_j (x_i^1 - a)(x_j^1 - a) x_j^1 + \right. \\
 &\quad \left. \frac{1}{N} \sum_{j,u>1} (x_i^u - a)(x_j^u - a) x_j^1 \right) \\
 &= \text{sgn} \left((x_i^1 - a)(1 - a x_i^1) + R \right) \quad \text{media 0!} \\
 &= \text{sgn} (x_i^1)
 \end{aligned}$$

se puede hacer el diagrama de foros, no a depender de T, α

$\alpha: \frac{1+\alpha}{2} < 1$ (mayor parte de neuronas en estado -1)

se prede puros que $\alpha_c \approx \frac{1}{\left(\frac{1+\alpha}{2}\right) \left| \log\left(\frac{1+\alpha}{2}\right) \right|}$

de info que se puede almacenar en un patron es finita cada patron tiene muy poca info.



potwór 1

potwór 2

si el n° de neuronas
por potwór es muy
grande, el potwór 1 es
igual al potwór 2