


# Generalizaciones modelos de Hopfield. variables continuas

$$\tau_i \frac{du_i}{dt} = -u_i + \sum_{j=1}^N w_{ij} \underbrace{v_j}_{v_j = g(u_j)}$$


$w_{ij} = w_{ji}$  dinámica converge a su pto fijo



$$E = -\frac{1}{2} \sum_{i,j} w_{ij} v_i v_j + \sum_i \int_0^{v_i} g'(v) dv$$

$$\begin{aligned} \frac{dE}{dt} &= -\frac{1}{2} \sum_{i,j} w_{ij} \left( \frac{\partial v}{\partial \tau} v_j + v_i \frac{\partial v_j}{\partial \tau} \right) + \sum_i \underbrace{g'(v_i)}_{u_i} \frac{dv_i}{dt} \\ &= -\sum_{i,j} w_{ij} v_j \frac{dv_i}{dt} + \sum_i u_i \frac{dv_i}{dt} \\ &= \sum_i \frac{dv_i}{dt} \left[ u_i + \sum_j w_{ij} v_j \right] \\ &= \sum_i \underbrace{g'(u_i)}_{u_i} \frac{du_i}{dt} \end{aligned}$$

## implementación en hardware



memembrones (resistores con memoria)

$$C \frac{du_i}{dt} + \frac{u_i}{P} = \sum_j \frac{(V_j - u_i)}{R}$$

$$v_i = g(u_i)$$

$$\tau_i \frac{du_i}{dt} + u_i = \sum_j w_{ij} g(u_j)$$

$$C \frac{du_i}{dt} + \frac{u_i}{R_i} = \sum_j \frac{g(u_j)}{R_{ij}}$$

$$\underbrace{R_i C}_{\tau_i} \frac{du_i}{dt} + u_i = \sum_j g(u_j) \underbrace{\left( \frac{R_i}{R_{ij}} \right)}_{w_{ij}}$$

$$\tau_i = R_i C$$


$$\frac{1}{R_i} = \frac{1}{P} + \sum_j \frac{1}{R_{ij}}$$

$$w_{ij} = \frac{R_i}{R_{ij}}$$

Redes con "olvido"

: al pasar el límite de capacidad se olvido. lo que aprendió

↓  
requiere una modificación de la regla de Hebb para incluir el tiempo



$$w_{ij} = \frac{1}{N} \sum_{q=1}^P x_i^q x_j^q$$

$$u(t) = \begin{cases} 1 & 0 \leq t \leq 1 \\ 2 & 1 \leq t \leq 2 \\ 3 & 2 \leq t \leq 3 \\ \vdots & \end{cases}$$

$$\Rightarrow w_{ij}(t) = \frac{1}{N} \int_0^t x_i^{u(\tau)} x_j^{u(\tau)} d\tau$$

$$\frac{dw_{ij}}{dt} = \frac{x_i^{u(t)} x_j^{u(t)}}{N}$$

agregamos

$$\frac{dw_{ij}}{dt} = -\frac{w_{ij}}{2} + \frac{x_i^{u(t)} x_j^{u(t)}}{N}$$

$$\Rightarrow w_{ij}(t) = \int_0^t \frac{x_i^{u(\tau)} x_j^{u(\tau)}}{N} e^{-(t-\tau)/2} d\tau$$

los tiempos muy anteriores al tiempo  $t$  son olvidados

es razonable pedir  $\tau_c = 0.1 N$

$$w_{ij} = \frac{1}{N} \sum_q x_i^q x_j^q \rightarrow \text{sgm} \left( \frac{1}{N} \sum_q x_i^q x_j^q \right) P$$

↓  
clipping

Ley de Dale : sinapsis es inhibitoria o excitatoria de manera fija

Cada neurona tiene un solo tipo de sinapsis

↓ (cada neurona genera un solo tipo de neurotransmisor)

$$w_{ij} > 0 \quad \forall i \in \bar{n} \quad \text{or} \quad w_{ik} < 0 \quad \forall \bar{k}$$

Reglas de Hebb  $\rightarrow$  prora o todas las conexiones  
que no satisfacen la ley de Dale

aprendizaje Hebbiano - Paper Mishita



los neuronos en un ensemble están fuertemente  
conectados

porque: # de neuronas con alta frec durante  
el tiempo de delay es bajo

$$\bar{X} = [ \bar{x}^1 \quad \bar{x}^2 \quad \dots ]$$

$$\bar{X}^T X = \begin{pmatrix} \bar{x}^1 \\ \vdots \\ \bar{x}^N \end{pmatrix} \begin{bmatrix} \bar{x}^1 & \dots & \bar{x}^N \end{bmatrix}$$

$x_1 \quad x_2 \quad \dots$