



Aprendizaje no supervisado

- los datos de entrada tienen una estructura estadística no trivial
- se impone alguna regla de modificación de las conexiones sinápticas



$$\begin{array}{c}
 \vec{x} \\
 \begin{array}{c} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{array}
 \end{array}
 \begin{array}{c}
 \vec{w} \\
 \begin{array}{c} / \\ / \\ / \\ / \\ / \end{array}
 \end{array}
 \begin{array}{c}
 0 \\
 0 \\
 0 \\
 0 \\
 0
 \end{array}
 \quad V = \sum_{j=1}^N w_j x_j = \vec{w} \cdot \vec{x}$$

Postulado

$$\Delta w_i = \eta V x_i \Rightarrow \text{¿los pesos convergen?}$$

$$\begin{aligned}
 0 = \underbrace{\langle \Delta w_i \rangle}_{\substack{\text{los} \\ \text{pesos} \\ \text{no se} \\ \text{modifican} \\ \text{más}}} &= \eta \langle V x_i \rangle = \eta \left\langle \sum_{j=1}^N w_j x_i x_j \right\rangle \\
 &= \eta \sum_{j=1}^N w_j \underbrace{\langle x_i x_j \rangle}_{C_{ij}}
 \end{aligned}$$

\downarrow
 es simétrica
 \downarrow
 los elementos diagonales son 1
 $\Rightarrow C_{ii} = 1$

$$\langle \Delta \vec{w} \rangle = \bar{C} \vec{w} \eta \quad (\text{matricial})$$

$$\bar{V}_\alpha : \text{autovectores de } \bar{C} \quad | \quad \bar{C} \bar{V}_\alpha = \lambda_\alpha \bar{V}_\alpha$$

$$\lambda_\alpha : \text{autovalores de } \bar{C}$$

$$\text{si } \lambda_\alpha \neq \lambda_\beta \Rightarrow \bar{V}_\alpha \cdot \bar{V}_\beta = 0$$

$$\bar{W} = \sum_{\alpha=1}^N w_\alpha \bar{V}_\alpha$$

expansión
de \bar{W} en
autovectores
de \bar{V}_α

$$\Rightarrow \bar{C} \bar{W} = \sum_{\alpha=1}^N w_\alpha \bar{C} \bar{V}_\alpha = \sum_{\alpha=1}^N w_\alpha \lambda_\alpha \bar{V}_\alpha$$

$$\Rightarrow \langle \Delta \bar{W} \rangle = \eta \sum_{\alpha=1}^N w_\alpha \lambda_\alpha \bar{V}_\alpha \stackrel{?}{=} 0$$

no! (no converge)

el cambio de $\Delta \bar{W}$ es
en dirección del autovector λ_α
más grande

$$\downarrow$$

N veces: $\langle \Delta \bar{W} \rangle = \eta \sum_{\alpha=1}^N w_\alpha \lambda_\alpha^2 \bar{V}_\alpha$

A tiempos largos \bar{W} apunta en dirección de
máximo autovalor

Postulemos ahora

$$\Delta w_i = \eta V (x_i - V w_i) \quad \text{regla de ojo}$$

converge!

Calculemos

$$\begin{aligned} \langle \Delta w_i \rangle &= \eta \left[\sum_j w_j \langle x_i x_j \rangle - \left\langle \left(\sum_j w_j x_j \right)^2 w_i \right\rangle \right] \\ &= \eta \left[\sum_j c_{ij} w_j - \sum_{j,j'} w_j w_{j'} \underbrace{\langle x_j x_{j'} \rangle}_{c_{jj'}} w_i \right] \\ &= \eta \left[\sum_j c_{ij} w_j - \left[\sum_{j,j'} w_j c_{jj'} w_{j'} \right] w_i \right] \end{aligned}$$

$$\Rightarrow \langle \Delta \bar{W} \rangle_i = \eta \left[(\bar{C} \bar{W})_i - [(\bar{W}^T \bar{C} \bar{W}) w_i] \right]$$

$$\Rightarrow \text{se tiene convergencia si } \bar{C} \bar{W} - [\bar{W}^T \bar{C} \bar{W}] \bar{W} = 0$$

$$\text{si } \bar{W} / \bar{C} \bar{W} = \lambda \bar{W} \quad \Rightarrow \quad \lambda \bar{W} - [\lambda |\bar{W}|^2] \bar{W} = 0$$

$$\Delta \bar{W} [1 - |\bar{W}|^2] = 0$$

\Rightarrow hay convergencia si \bar{W} es autovector de \bar{C} con norma 1. ($|\bar{W}|^2 = 1$)

Se puede pensar a el punto donde converge el sist como un punto fijo. Evaluemos su estabilidad

$$\bar{W} = \bar{V}_d + \bar{\varepsilon} \quad \bar{C} \bar{V}_d = \lambda \bar{V}_d \quad (|\bar{V}_d|^2 = 1) \quad |\bar{\varepsilon}| \ll 1$$

$$\begin{aligned} \langle \Delta \bar{\varepsilon} \rangle &= \langle \Delta \bar{W} \rangle = \eta \left[(\bar{C} \bar{W}) - [(\bar{W}^T \bar{C} \bar{W}) \bar{W}] \right] \\ &= \eta \left[\bar{C} (\bar{V}_d + \bar{\varepsilon}) - [(\bar{V}_d + \bar{\varepsilon})^T \bar{C} (\bar{V}_d + \bar{\varepsilon})] (\bar{V}_d + \bar{\varepsilon}) \right] \\ &= \eta \left[\bar{C} \bar{V}_d + \bar{C} \bar{\varepsilon} - (\bar{W}^T \bar{C} \bar{V}_d) (\bar{V}_d + \bar{\varepsilon}) (\bar{V}_d + \bar{\varepsilon}) \right] \\ &= \eta \left[\bar{C} \bar{V}_d - (\bar{W}^T \bar{C} \bar{V}_d) \bar{V}_d \right] \\ &\quad + \eta \left[\bar{C} \bar{\varepsilon} - \underbrace{[\bar{V}_d^T \bar{C} \bar{V}_d]}_{\lambda} \bar{\varepsilon} - 2 \underbrace{[\bar{\varepsilon}^T \bar{C} \bar{V}_d]}_{\lambda \bar{V}_d} \bar{V}_d \right] \\ &\quad + \mathcal{O}(\varepsilon^2) \end{aligned}$$

$$= \eta \left[\bar{C} \bar{\varepsilon} - \lambda \bar{\varepsilon} - 2 \lambda (\bar{\varepsilon}^T \bar{V}_d) \bar{V}_d \right]$$

$$\bar{V}_p^T \langle \Delta \bar{\varepsilon} \rangle = \eta \left[\bar{V}_p^T \bar{C} \bar{\varepsilon} - 2 \lambda (\bar{\varepsilon}^T \bar{V}_0) \bar{V}_p^T \bar{V}_d - \lambda \bar{V}_p^T \bar{\varepsilon} \right]$$

$$= \eta \left[(\bar{V}_p^T \bar{C} \bar{\varepsilon}) - 2 \lambda (\bar{\varepsilon}^T \bar{V}_p) \delta_{\alpha\beta} - \lambda (\bar{V}_p^T \bar{\varepsilon}) \right]$$

$$= \eta \left[\underbrace{\lambda_\beta - \lambda_\alpha - 2 \lambda_\beta \delta_{\alpha\beta}}_{\begin{matrix} < 0 & \text{estable} \\ > 0 & \text{inestable} \end{matrix}} \right] (\bar{V}_p^T \bar{\varepsilon})$$

$$\text{si } \beta = \alpha \Rightarrow -2 \lambda_\alpha < 0 \rightarrow \text{estable}$$

$$\beta \neq \alpha$$

$$\lambda_\beta - \lambda_\alpha$$

\downarrow

$$\text{si } \lambda_\alpha \geq \lambda_\beta \forall \beta$$

$$\Rightarrow \lambda_\beta - \lambda_\alpha < 0$$


$$\Rightarrow \text{el eq. es estable}$$

los \bar{W} convergen allí

\Leftarrow

hay un solo
punto fijo estable
en el autovector
con máximo
autovalor

la única dirección en la que
la perturbación es estable es
la del máximo autovalor



$$\vec{v} = \vec{w} \cdot \vec{x}$$


↓
proyección

$$\begin{aligned} \langle v^2 \rangle &= \sum_{j,j'} w_j w_{j'} \langle x_j, x_{j'} \rangle \\ &= \vec{w}^T \vec{C} \vec{w} \quad (\vec{w} = \sum_k w_k \vec{x}_k) \\ &= \sum_k w_k^2 \lambda_k \end{aligned}$$

⇒ el vec estorle es el
que maximiza $\langle v^2 \rangle$
↓
máxima
varianza
($\langle v \rangle = 0$)

función de costo $E = \frac{1}{2} \sum_{j,j'} w_j c_{ij} w_{j'} + \frac{1}{4} \left(\sum_i w_i^2 \right)^2$

generalización de la red de oja



$$\begin{aligned} \vec{v} &= \vec{w} \cdot \vec{x} \\ v_i &= \sum_{j=1}^n w_{ij} x_j \\ i &= 1, \dots, n \end{aligned}$$

la salida de la primera unidad va a
don la proyección de la entrada en
dirección del autovector más grande
la salida de la seg. unidad va a
don la proyección de la entrada en
dirección de seg autovector más grande

⋮ así siguiendo

PCA: principal component analysis