

Estadística de trenes de spikes

Pablo Chegade

pablo.chegade@ib.edu.ar

Redes Neuronales, Instituto Balseiro, CNEA-UNCuyo, Bariloche, Argentina, 2023

En el ámbito de la neurociencia, el estudio de la actividad eléctrica neuronal es esencial para comprender los mecanismos subyacentes al procesamiento de la información en el cerebro. Una herramienta fundamental en este estudio es el análisis estadístico de los spikes o potenciales de acción. En este trabajo, se analizaron datos experimentales obtenidos por Ariel Rokem a través de electrodos intracelulares en un receptor acústico de un saltamontes. Estos datos comprenden la envolvente de una onda sonora presentada al animal y la respuesta neuronal correspondiente en forma de spikes. Se registraron 128 series de datos, cada una correspondiente a la respuesta neuronal ante el mismo estímulo. Todas las series de datos tienen como dato inicial un spike, el cual fue ignorado en el análisis.

I. DISTRIBUCIÓN DE INTERVALOS ENTRE SPIKES




Figura 1: Aproximación de la distribución de intervalos entre spikes $P(ISI)$ de la neurona.

A partir de los datos de spikes, se determinaron los intervalos entre spikes (Inter Spike Interval o "ISI" por sus siglas en inglés). Estos intervalos se definen como la diferencia temporal entre spikes consecutivos. A continuación, se construyó un histograma de estos intervalos que, normalizado, constituye una aproximación a la distribución de intervalos $P(ISI)$ de la neurona, como se muestra en la figura 1. La ausencia de valores cercanos a cero refleja el período refractario de la neurona, un intervalo post-spike durante el cual es improbable que se genere otro spike. Para valores elevados de ISI, la distribución

muestra un decaimiento que se asemeja a una función exponencial decreciente. En valores intermedios de ISI, se observa un comportamiento atípico con un pico seguido de una meseta de valor aproximadamente constante.

Además, se puede hacer una caracterización cuantitativa de la distribución. La media de la distribución es $\langle ISI \rangle = 8,496$ ms y la desviación estándar, $\sigma_{ISI} = 5,663$ ms, resultando en un Coeficiente de Variabilidad $CV = \langle ISI \rangle / \sigma_{ISI} = 0,667$.

II. DISTRIBUCIÓN DEL NÚMERO DE SPIKES




Figura 2: Aproximación la distribución del número de spikes $P(N)$ en cada realización.

Otro modo de caracterizar la respuesta neuronal es estudiando la variación de la respuesta ante el mismo estímulo. Para tal fin se contabilizó el número total de spikes, N , en cada realización y, mediante un histograma, se estimó la probabilidad $P(N)$ de obtener N spikes en una realización. Los resultados se muestran en la figura 2. Se observa que existe una variabilidad en el número de spikes generados en respuesta al mismo estímulo. Esto podría deberse a que el estímulo sonoro no es el único estímulo que recibe la neurona. Hay otros procesos que ocurren en el cerebro o en las neuronas cercanas que también la están estimulando y, por lo tanto, cambiando su respuesta. Cuantitativamente, la media de esta distribución es $\langle N \rangle = 117$, mientras que la desviación estándar es $\sigma_N = 13,5$. De este modo, el Factor de Fano F es $F = \sigma_N^2 / \langle N \rangle = 1,6$.

En base a los resultados obtenidos, se puede determinar si el proceso de generación de spikes es del tipo rene-

wal. En estos procesos se cumple la relación $F = CV^2$. Sin embargo, en este análisis F es 1.6, mientras que CV^2 es 0.444. Por lo tanto, el proceso no es del tipo renewal. Esta discrepancia es coherente con la naturaleza de las neuronas reales, donde los ISI no son eventos independientes ya que la neurona tiene "memoria" del comportamiento previo.




Figura 3: Tasa de disparo para un ancho de caja de a. $T = 2$ ms, b. $T = 300$ ms y c. $T = 1000$ ms.

III. TASA DE DISPARO

Una herramienta útil para caracterizar la respuesta generada es la tasa de disparo, que se define como el número

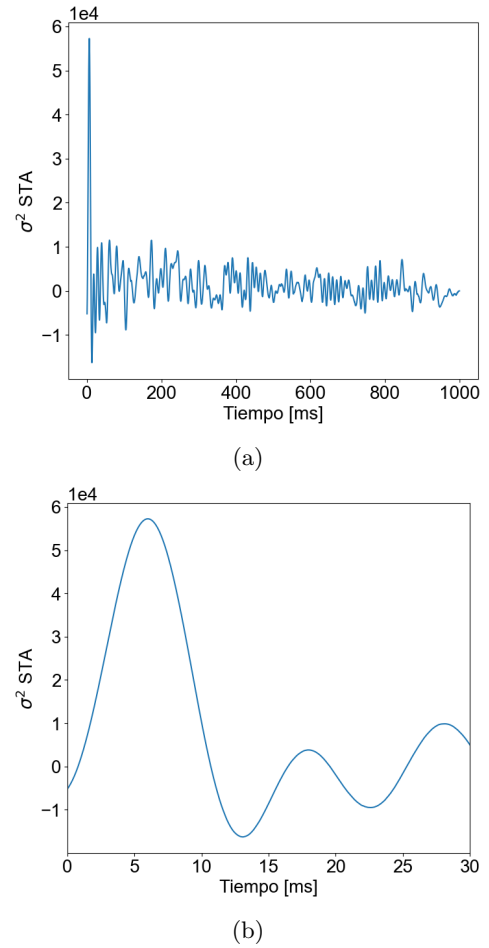


Figura 4: Spike-Trigger-Average (STA) multiplicado por la constante de normalización σ^2 en función del tiempo t . En la figura 4.a., se grafica para todo el intervalo temporal, mientras que en la figura 4.b. se grafica una ampliación para un intervalo menor.

de spikes por unidad de tiempo. Esta tasa puede determinarse de dos maneras: promediando las señales de respuesta o, alternativamente, promediando el número de spikes en un intervalo temporal, o "caja", de ancho T para cada tiempo.

En este análisis, se eligió la segunda metodología. La tasa de disparo, calculada para diferentes anchos de caja T , se presenta en la figura 3. Se observa que el histograma es sensible al ancho T seleccionado. Con un T pequeño, como se observa en la figura 3.a, la tasa refleja directamente las señales delta de los spikes. A medida que T se incrementa, la tasa de disparo revela información adicional, como se ve con $T = 30$ ms en la figura 3.b. Este comportamiento se mantiene en un amplio rango de T . Además, se observa un efecto de borde en los extremos temporales: la tasa decae notoriamente. Si T es excesivamente grande, como en la figura 3.c, el comportamiento general cambia debido a la pérdida de detalle de la información. Además, los efectos de borde se vuelven más




Figura 5: Diferencia en la tasa de disparo respecto a su valor medio $r - r_0$ y respuesta del modelo lineal r_{model} adimensionalizada por 10^9 en función del tiempo t .

notorios ya que el ancho de la caja se vuelve comparable con la duración total del intervalo de medición.

IV. RELACIÓN LINEAL ENTRE ESTÍMULO Y RESPUESTA

Hasta el momento, solo se ha caracterizado la respuesta neuronal. También resulta de gran interés estudiar la relación entre el estímulo presentado y la respuesta generada. Para entender tal relación, se puede considerar una descripción lineal de la respuesta en función del estímulo. Esta relación se puede expresar como

$$r(t) = r_0 + \int_0^{\infty} d\tau D(\tau) S(t - \tau)$$

V. APÉNDICE

A continuación se desarrolla el código empleado durante este trabajo implementado en Python.

```

1  #Import libraries
2  import matplotlib.pyplot as plt
3  import numpy as np
4
5  #Import data .dat
6  spikes = np.loadtxt('spikes.dat')
7  stimulus = np.loadtxt('stimulus.dat')
8
9  def ISI_calculation(realizacion):
10     #Calculo los ISI de una realizaci n realizacion es un vector de 0 y 1. Devuelve un
        vector con los ISI en unidades de 0.1 ms
11     ISI = []
12     index_last_spike = 0
13     for i in range(1,len(realizacion)):
14         if realizacion[i] == 1:
15             ISI.append(i-index_last_spike)
16             index_last_spike = i

```

donde r_0 es una constante y $D(t)$ es una función denominada como kernel lineal.

Asumiendo que el valor medio del estímulo $S(t)$ es nulo, se obtiene que r_0 es el valor medio de la tasa de disparo, 116 Hz en este caso. Al despreciar el tiempo de autocorrelación del estímulo, el kernel lineal adquiere la forma

$$D(t) = \frac{1}{\sigma^2} \sum_{SPIKE} S(t_{SPIKE} - t).$$

Aquí, σ es una constante de normalización, t_{SPIKE} es el tiempo al que ocurre un spike y la sumatoria se realiza sobre todos los spikes de todas las realizaciones. Con estas aproximaciones, el kernel lineal se conoce como Spike-Trigger-Average (STA).

El STA se presenta en función del tiempo en la figura 4. En esta figura, se destaca un pico para tiempos cortos alrededor de $T_0 = 8$ ms. Este sería el tiempo para el cual la neurona tiene mayor probabilidad de generar un spike tras un estímulo. Para tiempos más largos, el STA decae y muestra variabilidad, lo cual indica que la sensibilidad de la neurona disminuye con el tiempo.

Basándose en el STA, se calculó la respuesta $r_{model}(t)$ del modelo lineal. Para calcular la integral, se discretizó el tiempo y se limitó el intervalo de integración entre 0 y T_0 para evitar la variabilidad en $D(t)$ para tiempos más largos. Consecuentemente, como se tiene la señal estímulo a partir de $t = 0$, se evaluó la respuesta a partir del tiempo $t = T_0$. Aunque sería necesario conocer la constante σ para comparar $r(t)$ con $r_{model}(t)$, se puede comparar $r(t) - r_0$ con $r_{model}(t)$ adimensionalizado arbitrariamente por 10^9 . Esta comparación se muestra en la figura 5 para un rango limitado de tiempo usando una ventana temporal de 300 ms para calcular $r(t)$. Se puede observar que el modelo captura aproximadamente el comportamiento de la respuesta, incluidos los picos y las depresiones, aunque presenta una gran variabilidad.

```

17     return np.array(ISI)
18
19 def ISI_total_calculation(realizaciones):
20     #Calculo los ISI de todas las realizaciones
21     #realizaciones es una matriz de 0 y 1
22     #Devuelve un vector con los ISI en unidades de 0.1 ms
23     ISI = np.array([])
24     for realizacion in realizaciones:
25         ISI = np.concatenate([ISI, ISI_calculation(realizacion)])
26     return ISI
27 ISI_total = ISI_total_calculation(spikes)
28 factor_to_ms = 1/10
29
30 #Grafico el histograma normalizado de los ISI
31 fig, ax = plt.subplots(1,1, figsize=(8,7))
32 ax.hist(ISI_total*factor_to_ms, bins=100, density = True) #density=True
33 ax.set_xlabel('ISI [ms]')
34 ax.set_ylabel('P(ISI)')
35 ax.set_xlim([0,40])
36 plt.show()
37
38 #Calculo media, desviación estandar y CV
39 media = np.mean(ISI_total)
40 desvio = np.std(ISI_total)
41 CV = desvio/media
42 print(f'Media: {media*factor_to_ms} [ms]')
43 print(f'Desviación estandar: {desvio*factor_to_ms} [ms]')
44 print(f'CV: {CV}')
45
46 def N_calculation(realizaciones):
47     #Calculo N. Devuelve un vector con los N
48     return np.sum(realizaciones, axis=1)
49
50 #Histograma de Ns normalizado
51 fig, ax = plt.subplots(1,1, figsize=(8,7))
52 ax.hist(N_calculation(spikes), bins=15) #density=True
53 ax.set_xlabel('N')
54 ax.set_ylabel('P(N)')
55 plt.show()
56
57 #Calculo media, desviación estandar y factor de Fano
58 media = np.mean(N_calculation(spikes))
59 desvio = np.std(N_calculation(spikes))
60 Fano = desvio**2/media
61 print(f'Media: {media}')
62 print(f'Desviación estandar: {desvio}')
63 print(f'Fano: {Fano}')
64
65 def firing_rate_total_calculation(realizaciones, T):
66     """
67     Calculo la tasa de disparo usando una caja de ancho T expresada en unidades de 0.1
68     ms, es decir, como índice. Tiene que ser múltiplo de 2
69     """
70     N_realizaciones = len(realizaciones)
71     return np.convolve(np.sum(realizaciones, axis = 0), np.ones(T), mode = "same")/T/
72         N_realizaciones
73
74 #Grafico la tasa de disparo
75 def plt_tasa_de_disparo(T, save = False):
76     fig, ax = plt.subplots(1,1, figsize=(8,6))
77     y_vec = firing_rate_total_calculation(spikes[:,1:], T)/factor_to_ms*1e3
78     x_vec = np.arange(len(y_vec))*factor_to_ms
79     ax.plot(x_vec, y_vec)
80     ax.set_xlabel('Tiempo [ms]')

```

```

79     ax.set_ylabel('Tasa de disparo [Hz]')
80     ax.set_title(f"Ancho de caja T={T/10} ms")
81     plt.show()
82     if save == True:
83         fig.savefig(f'tasa_de_disparo_{T}.png', bbox_inches='tight')
84
85 plt_tasa_de_disparo(300, save = False)
86
87 def t_spikes_calculation(realizacion):
88     #Calculo los tiempos a los que se da un spike (t_spikes) de una realizaci n
89     #realizacion es un vector de 0 y 1
90     #Devuelve un vector con los t_spikes en unidades de 0.1 ms
91     tiempos = np.array(realizacion)*np.linspace(0, len(realizacion), len(realizacion))
92     #Descarto tiempos nulos
93     t_spike = tiempos[tiempos != 0]
94     return t_spike
95
96 def t_spikes_total_calculation(realizaciones):
97     #Calculo los tiempos a los que se da un spike (t_spikes) de todas las realizaciones
98     #realizaciones es una matriz de 0 y 1
99     #Devuelve un vector con los t_spikes en unidades de 0.1 ms
100    t_spike = np.array([])
101    for realizacion in realizaciones:
102        t_spike = np.concatenate([t_spike, t_spikes_calculation(realizacion)])
103    return t_spike
104
105 t_spikes_total = t_spikes_total_calculation(spikes)
106 def kernel_lineal(t, t_spikes_total, stimulus_vec):
107     '''
108     Calcula D*sigma**2 expresado en unidades de dB
109     t [0.1 ms]
110     '''
111     #Calculo la diferencia entre tiempos
112     dif = t_spikes_total - t
113     #Convierto el array de float a array de int
114     dif = np.array(dif, dtype=int)
115     #Elimino elementos negativos
116     dif = dif[dif >= 0]
117     #Eval o S en dif como ndices
118     S_dif = stimulus_vec[dif]
119     #Calculo D
120     D = np.sum(S_dif)
121     return D
122
123 def kernel_constante(realizaciones):
124     '''
125     Calcula r0: valor medio de la tasa de disparo expresado en unidades de 1/0.1 ms
126     '''
127     return np.mean(realizaciones)
128
129 #Calculo kernel_lineal y kernel_constante
130 D_vec = np.empty(len(stimulus[:,0]))
131 t_spikes_total = t_spikes_total_calculation(spikes)
132
133 for i in range(len(stimulus[:,0])):
134     D_vec[i] = kernel_lineal(i, t_spikes_total, stimulus[:,1])
135 r0 = kernel_constante(spikes[:,1:])
136 print(f"r0={r0/factor_to_ms*1e3} [Hz]")
137 #Grafico D
138 fig, ax = plt.subplots(1,1, figsize=(8,7))
139 ax.plot(np.arange(len(stimulus[:,0]))*factor_to_ms, D_vec, color = "tab:blue")
140 #Expreso el eje y en forma cient fica
141 ax.ticklabel_format(axis="y", style="sci", scilimits=(0,0))
142 # ax.plot(t_spikes_total)-

```

```

143 ax.set_xlabel('Tiempo [ms]')
144 ax.set_ylabel('$\sigma^2_{STA}$')
145 plt.show()
146
147
148 def modelo_lineal(r0, D_vec, stimulus_vec):
149     '''
150     Calcula la tasa de disparo r con el modelo lineal en funci n de r0, D_vec y
151     stimulus.
152     r(t) = r0 + int_0^infy D(t')*stimulus(t-t')
153     '''
154     r_model = np.empty(len(stimulus_vec))
155     Delta_t = factor_to_ms #Esta igualdad es una casualidad
156     for t in range(len(stimulus_vec)):
157         integral = 0
158         T0 = 300 #[0.1 ms]. L mite superior de la integral
159         if t < T0: #En esa regi no puedo hacer la integral
160             r_model[t] = 0
161         else:
162             for tau in range(T0):
163                 integral += D_vec[tau]*stimulus_vec[t-tau]*Delta_t
164             r_model[t] = integral
165     return r_model
166
167 r_model_vec = modelo_lineal(r0, D_vec, stimulus[:,1])
168 #Grafico r y r_model
169 fig, ax = plt.subplots(1,1, figsize=(8,7))
170 T = 300
171 r_vec = firing_rate_total_calculation(spikes[:,1:], T)
172
173 ind_min = 0
174 ind_max = 10000
175
176 ax.plot(np.arange(len(r_vec))[ind_min:ind_max]*factor_to_ms, (r_vec - r0)[ind_min:
177 ind_max], color = "tab:red", label = "$r_{-r_0}$")
178 ax.plot(stimulus[:,0][ind_min:ind_max], r_model_vec[ind_min:ind_max]/1e9, color = "tab:
179 blue", label = "$r_{model}$")
180 #Expreso eje y en forma cient fica
181 ax.ticklabel_format(axis="y", style="sci", scilimits=(0,0))
182 ax.set_ylabel('r')
183 ax.set_xlabel('t [ms]')
184 ax.legend()
185 plt.show()

```